

Estatísticas de criminalidade violenta por estado americano (por 100 mil habitantes): assassinatos, assaltos e estupro, além do percentual da população urbana.

Stefany Nicole Santos Alves^a

^aDepartamento de Ciência da Computação - UFCG

Resumo

Este trabalho aplica a metodologia de regressão linear múltipla (MRLM) ao clássico conjunto de dados Iris, coletado por Anderson e popularizado por Fisher, com o objetivo de modelar o comprimento da sépala a partir das demais variáveis morfológicas e da espécie da flor. Após uma análise exploratória uni e bivariada, incluindo correlações, box-plots e verificação de dados ausentes, ajustamos um modelo inicial com todas as variáveis morfológicas contínuas e identificamos multicolinearidade severa entre o comprimento e a largura da pétala. Comparamos modelos candidatos por AIC, BIC e teste F, selecionamos um modelo final e verificamos seus pressupostos através de análise de resíduos, gráfico de envelope simulado e identificação de pontos atípicos, de alavanca e influentes. Em seguida, incorporamos a espécie como variável qualitativa (dummy), discutindo a codificação por categoria de referência e o efeito de sua alteração sobre a interpretação dos coeficientes. Por fim, para dois conjuntos de valores das variáveis explicativas, apresentamos os intervalos de confiança para o valor médio esperado da variável resposta e os intervalos de predição para novas observações, com interpretação prática de ambos.

Áreas do Conhecimento:

estatística aplicada, modelagem preditiva

Palavras-Chave:

regressão linear múltipla, multicolinearidade, seleção de modelos, criminalidade, diagnóstico de resíduos

1 Introdução

A criminalidade é um tema importante para a análise de dados, pois diferentes fatores podem estar relacionados aos índices de violência. A base de dados utilizada neste trabalho, **USArrests**, reúne informações dos 50 estados americanos referentes ao ano de 1973. Ela contém o número de **prisões por assassinato** (**Murder**), **assalto** (**Assault**) e **estupro** (**Rape**), por 100 mil habitantes, além do percentual da população que vive em áreas urbanas (**UrbanPop**).

Neste trabalho, o objetivo é modelar o número de **prisões por assalto** (**Assault**) a partir das demais variáveis da base. Esse problema é interessante porque permite analisar como diferentes tipos de crimes e o nível de urbanização estão relacionados com a variável resposta, além de aplicar técnicas de regressão linear múltipla.

Especificamente, buscamos: (i) descrever a base de dados e realizar uma análise exploratória; (ii) ajustar um modelo inicial de regressão linear múltipla; (iii) avaliar a presença de multicolinearidade e selecionar um modelo mais adequado; (iv) verificar os pressupostos do modelo; e (v) interpretar os resultados obtidos.

2 Metodologia

Os dados correspondem aos 50 estados americanos no ano de 1973, sem valores ausentes, contendo quatro variáveis numéricas: **Murder**, **Assault**, **UrbanPop** e **Rape**. A análise exploratória compreendeu estatísticas descritivas, matriz de correlação, histogramas, boxplots e matriz de dispersão entre as variáveis.

2.1 Modelo de regressão linear múltipla

Seja y_i o número de **prisões por assalto** da i -ésima observação (estado). O modelo inicial, utilizando todas as demais variáveis da base como explicativas, é dado por

$$y_i = \beta_0 + \beta_1 \text{Murder}_i + \beta_2 \text{UrbanPop}_i + \beta_3 \text{Rape}_i + \varepsilon_i,$$

em que ε_i segue as suposições usuais do Modelo de Regressão Linear Múltipla (MRLM) [1]: média nula, variância constante, independência e normalidade.

A multicolinearidade entre as variáveis explicativas foi avaliada por dois critérios complementares: (a) a matriz de correlações entre as variáveis preditoras, em que valores absolutos de correlação maiores que 0,8 indicam possível multicolinearidade; e (b) o fator de inflação da variância (VIF), dado por $VIF_j = 1/(1 - R_j^2)$, em que R_j^2 é o coeficiente de determinação da regressão de X_j sobre as demais variáveis explicativas. Valores de VIF superiores a 5 indicam possível problema de multicolinearidade, enquanto valores acima de 10 sugerem multicolinearidade severa [1].

A seleção do modelo foi realizada utilizando os critérios de informação de Akaike (AIC) [2] e Bayesiano (BIC) [3], além do teste F para comparação entre modelos aninhados. Em ambos os critérios de informação, modelos com menores valores de AIC e BIC são preferíveis. Como apoio à seleção, também foi utilizado o procedimento automático *stepwise* (*step*), baseado no critério AIC, permitindo comparar a seleção automática com a escolha baseada na interpretação estatística dos resultados.

2.2 Diagnóstico do modelo

A adequação do modelo selecionado foi avaliada por meio da análise gráfica dos resíduos, utilizando os gráficos de resíduos versus valores ajustados, quantil-quantil (Q-Q Plot), escala-localização e resíduos versus alavancagem. Esses gráficos permitem verificar os principais pressupostos do Modelo de Regressão Linear Múltipla, como linearidade, homocedasticidade, normalidade dos resíduos e a presença de observações influentes [1].

Também foram analisadas possíveis observações atípicas, de alavanca e influentes utilizando os resíduos studentizados ($|t_i| > 2$), os valores de alavancagem ($h_{ii} > 2p/n$) e a distância de Cook ($D_i > 4/n$) [1,4,5]. Caso fossem identificadas observações com influência significativa sobre o ajuste, seria avaliado o impacto de sua remoção por meio do reajuste do modelo.

Por fim, para facilitar a comparação da influência das variáveis explicativas, foram calculados os coeficientes padronizados do modelo final. Como as variáveis estão em escalas diferentes, essa padronização permite comparar diretamente a contribuição relativa de cada variável para explicar o número de prisões por assalto.

2.3 Variáveis explicativas

Diferentemente de outros conjuntos de dados que possuem variáveis categóricas, a base **USArrests** é composta apenas por variáveis numéricas (*Murder*, *UrbanPop* e *Rape*), utilizadas como variáveis explicativas do modelo. Dessa forma, não foi necessária a criação de variáveis *dummy* nem a definição de uma categoria de referência. O modelo foi ajustado diretamente utilizando essas variáveis contínuas para explicar o número de prisões por assalto (*Assault*).

2.4 Inferência preditiva

Para um conjunto de valores das variáveis explicativas (*Murder*, *UrbanPop* e *Rape*), é possível realizar dois tipos de inferência [1]: o **intervalo de confiança** para o valor médio esperado de prisões por assalto, que estima a média da resposta para estados com essas características, e o **intervalo de predição** para uma **nova observação**, que estima um valor futuro de prisões por assalto para um estado com as mesmas características. Como o intervalo de predição considera também a variabilidade entre observações individuais, ele é naturalmente mais amplo que o intervalo de confiança. Ambos foram calculados para dois conjuntos hipotéticos de valores das variáveis explicativas, escolhidos dentro do intervalo observado na base de dados.

3 Resultados

3.1 Descrição da base de dados

A base **USArrests** possui $n = 50$ observações, correspondentes aos 50 estados americanos, e 4 variáveis numéricas (Tabela 1), sem valores ausentes.

Tabela 1: Variáveis da base de dados USArrests, descrição e unidade de medida.

Variável	Descrição	Unidade
Murder	Prisões por assassinato (por 100 mil habitantes)	prisões/100 mil habitantes
Assault	Prisões por assalto (variável resposta, por 100 mil habitantes)	prisões/100 mil habitantes
UrbanPop	Percentual da população urbana	%
Rape	Prisões por estupro (por 100 mil habitantes)	prisões/100 mil habitantes

3.2 Análise exploratória

A Tabela 2 apresenta as estatísticas descritivas das variáveis da base USArrests.

Tabela 2: Média e desvio-padrão (dp) das variáveis da base USArrests.

	Variável	Média	Desvio.padrão
Murder	Murder	7.79	4.36
Assault	Assault	170.76	83.34
UrbanPop	UrbanPop	65.54	14.47
Rape	Rape	21.23	9.37

A Figura 1 apresenta os box-plots das variáveis da base. Observa-se que Assault e Rape apresentam maior dispersão dos dados, enquanto UrbanPop possui distribuição mais concentrada. Além disso, algumas variáveis apresentam observações mais afastadas da maior parte dos dados, indicando possíveis valores extremos.




Figura 1. Box-plots das variáveis da base USArrests.

3.2.1 Análise de correlação

A Figura 2 apresenta a matriz de correlações entre as quatro variáveis da base.




Figura 2. Matriz de correlações entre as variáveis da base USArrests.

Com relação à análise de correlação, espera-se que as variáveis explicativas apresentem correlação com a variável resposta *Assault*, mas que as correlações entre as próprias variáveis explicativas não sejam excessivamente elevadas, pois isso pode indicar multicolinearidade. Como regra geral, correlações absolutas superiores a 0,8 merecem atenção.

Examinando a Figura 2, observa-se que:

1. A variável resposta *Assault* apresenta correlação positiva com *Murder* e *Rape*, indicando que estados com maiores índices de prisões por assassinato e estupro tendem também a apresentar maiores índices de prisões por assalto.
2. A variável *UrbanPop* apresenta correlação mais fraca com as demais variáveis, sugerindo menor associação linear com os índices de criminalidade.
3. As correlações entre as variáveis explicativas (*Murder*, *UrbanPop* e *Rape*) serão avaliadas juntamente com o VIF para verificar a existência de multicolinearidade.

3.2.2 Multicolinearidade: o VIF

Para quantificar a multicolinearidade sugerida pela análise de correlação, ajustamos um modelo inicial considerando *Assault* como variável resposta e *Murder*, *UrbanPop* e *Rape* como variáveis explicativas.

Tabela 3: Estimativas dos coeficientes do modelo inicial.

Termo	Estimativa	Erro Padrão	Estatística t	p-valor
Intercepto	-15.4520	31.8581	-0.4850	0.6300
Murder	12.4700	1.8533	6.7286	0.0000
UrbanPop	0.6304	0.5054	1.2474	0.2186
Rape	2.2502	0.9432	2.3857	0.0212

Tabela 4: Fator de inflação de variância (VIF) das variáveis explicativas.

Variável	VIF
Murder	1.54
UrbanPop	1.26
Rape	1.84

O modelo inicial será avaliado por meio do coeficiente de determinação ajustado, da significância dos coeficientes e dos valores de VIF. Valores de VIF superiores a 5 indicam possível multicolinearidade, enquanto valores acima de 10 caracterizam um problema mais severo. Caso seja identificada multicolinearidade relevante, será realizada a seleção de um modelo mais adequado antes da análise dos pressupostos.

3.3 Seleção do modelo final

3.3.1 Seleção automática via `step`

3.4 Diagnóstico do modelo selecionado

3.4.1 Identificação de pontos atípicos, de alavanca e influentes

3.4.2 Impacto da remoção dos pontos influentes

3.5 Interpretações do modelo selecionado

3.5.1 Coeficientes padronizados

3.6 Regressão com variáveis dummy (a espécie como explicativa)

3.6.1 Modelo sem `Petal.Length`, com a espécie

3.6.2 Alterando a categoria de referência

3.7 Comparação geral dos modelos

4 Previsões

4.1 Intervalo de confiança para o valor médio esperado

4.2 Intervalo de predição para uma nova observação

Referências

1. Kutner M, Nachtsheim C, Neter J, Li W. 2004 *Applied Linear Statistical Models - Fifth Edition*. New York: McGraw-Hill/Irwin.
2. Akaike H. 1974 A New Look at the Statistical Model Identification. *IEEE Transactions on Automatic Control* **19**, 716–723.
3. Schwarz G. 1978 Estimating the Dimension of a Model. *The Annals of Statistics* **6**, 461–464.
4. Cook RD. 1977 Detection of Influential Observation in Linear Regression. *Technometrics* **19**, 15–18.
5. Cook RD, Weisberg S. 1982 *Residuals and Influence in Regression*. New York: Chapman and Hall.